

Prediksi Risiko Konsumsi Narkoba Menggunakan Deep Neural Network: Studi Lanjutan dari Random Forest Model

Disusun Oleh:

- Muhammad Ichsan Junaedi (241572010024)
- Amanda Wijayanti (241572010006)

Dosen Pengampu: Hendri Kharisma S.Kom, M.T

Program Studi Sistem Informasi

Sekolah Tinggi Manajemen Informatika dan Komputer TAZKIA
Raya Dramaga Blok Radar Baru No.8, RT.03/RW.03, Margajaya, Kec. Bogor Bar.,
Kota Bogor, Jawa Barat 16116, Indonesia

BAB 1: PENDAHULUAN

1.1 Latar Belakang

Penyalahgunaan narkoba adalah krisis kesehatan global yang memerlukan metode identifikasi dini yang akurat. Pada penelitian sebelumnya (UTS), kami berhasil mengembangkan model prediksi risiko menggunakan algoritma Random Forest dengan akurasi 86.21% dan ROC-AUC 0.9347. Model tersebut terbukti efektif dan mampu melampaui baseline penelitian Fehrman et al. (2017).

Meskipun hasil tersebut sangat baik, Random Forest sebagai metode traditional machine learning memiliki keterbatasan dalam menangkap hubungan non-linear yang sangat kompleks antar fitur kepribadian personality traits. Oleh karena itu, penelitian lanjutan ini akan menerapkan Deep Neural Network (DNN). Pendekatan Deep Learning dipilih karena kemampuannya melakukan automatic feature learning dan mengenali pola hirarkis yang mungkin terlewatkan oleh model berbasis pohon tree-based, dengan tujuan untuk melihat apakah performa prediksi dapat ditingkatkan lebih jauh.

1.2 Rumusan Masalah

1. Bagaimana performa dan kemampuan generalisasi Deep Neural Network dibandingkan dengan Random Forest dalam memprediksi risiko konsumsi narkoba?
2. Apakah kompleksitas arsitektur DNN memberikan peningkatan signifikan dibandingkan efisiensi Random Forest?

1.3 Tujuan Penelitian

1. Implementasi Deep Learning: Membangun model DNN untuk klasifikasi biner (user vs non-user) sebagai pemenuhan Tugas Besar UAS.
2. Optimasi Arsitektur: Melakukan hyperparameter tuning (layer, neurons, dropout) menggunakan Keras Tuner untuk mendapatkan model terbaik.
3. Studi Komparasi: Membandingkan hasil DNN dengan model Random Forest (UTS) dari aspek akurasi, stabilitas (overfitting), dan biaya komputasi.
4. Analisis Fitur: Menggunakan metode SHAP untuk memahami fitur mana yang paling berpengaruh dalam model black-box DNN.

1.4 Manfaat Penelitian

Manfaat Akademik:

- Perbandingan empiris antara traditional ML (Random Forest) dan Deep Learning (DNN) pada healthcare prediction serta pemahaman mendalam tentang efektivitas Deep Learning untuk tabular data.

Manfaat Metodologis:

- Framework komprehensif untuk implementasi DNN pada dataset tidak seimbang imbalanced dan praktik terbaik untuk regularisasi pada dataset skala menengah.

Manfaat Sosial:

- Model alternatif untuk skrining awal penyalahgunaan narkoba dengan potensi akurasi lebih baik.
-

BAB 2: DESKRIPSI DATASET

2.1 Sumber Dataset

- **Repository:** UCI Machine Learning Repository
- **Judul:** Drug Consumption (Quantified)
- **URL:** <https://archive.ics.uci.edu/dataset/373/drug+consumption+quantified>
- **Paper:** Fehrman et al. (2017) - arXiv:1506.06297v2
- **Lisensi:** Open source
- **Format:** CSV

2.2 Struktur Dataset

Dataset terdiri dari 1,885 responden dengan 24 fitur input (setelah encoding) dan 1 binary target.

A. Data Demografi (5 fitur)

Fitur	Tipe	Encoding	Jumlah Fitur
Age	Ordinal	Label Encoding	(0-5) 1
Gender	Binary	Binary Encoding	1
Education	Ordinal	Label Encoding	(0-8) 1
Country	Nominal	One-Hot Encoding	7
Ethnicity	Nominal	One-Hot Encoding	7

B. Personality Traits - NEO-FFI-R (5 fitur)

Semua personality scores sudah standardized (mean=0, std=1):

Trait	Kode	Deskripsi
Neuroticism	Nscore	Kecenderungan emosi negatif (anxiety, depression)
Extraversion	Escore	Keaktifan sosial dan energi positif
Openness	Oscore	Keterbukaan pengalaman baru, kreativitas
Agreeableness	Ascore	Sikap kooperatif, empati
Conscientiousness	Cscore	Kedisiplinan, kontrol impuls

C. Behavioral Measures (2 fitur)

Fitur	Instrumen	Deskripsi
Impulsiveness	BIS-11	Bertindak tanpa berpikir panjang
Sensation Seeking	ImpSS	Pencarian pengalaman berisiko

D. Target Variable (Binary Classification)

User (Class 1): Responden menggunakan minimal 1 illegal drug dalam setahun terakhir (CL3-CL6)

Non-user (Class 0): Tidak menggunakan illegal drugs atau terakhir >1 tahun lalu (CL0-CL2)

Class Distribution:

- Non-User (0): 710 sampel (37.67%)
- User (1): 1,175 sampel (62.33%)
- Imbalance ratio: 0.60:1

2.3 Data Split (Identik dengan RF Model)

- Training Set: 1,508 sampel (80%)
- Testing Set: 377 sampel (20%)
- Stratified sampling untuk mempertahankan proporsi kelas

2.4 Karakteristik Dataset

Kesesuaian dengan DNN:

Kelebihan:

- Clean data (no missing values)
- Standardized features (siap untuk neural networks)
- Adequate sample size (1,885 samples - cukup untuk DNN sederhana)
- Balanced validation split
- Mix of continuous (personality) dan categorical (demographics) features

Tantangan:

- Medium-sized dataset (bukan big data) - risk of overfitting
- Tabular data (DNN biasanya excel di image/text/sequence)
- Class imbalance (perlu handling)
- High-dimensional input (24 features) relative to sample size

Strategi Mitigasi:

- Strong regularization (Dropout, L2, BatchNorm)
- Early stopping
- Moderate network depth (tidak terlalu deep)
- Data augmentation tidak applicable (tabular data)
- Comprehensive drug coverage (18 substances)

BAB 3: METODOLOGI

3.1 Preprocessing

Proses preprocessing dilakukan identik dengan model Random Forest untuk memastikan perbandingan yang adil fair comparison:

- Validasi Data: Cek missing values dan tipe data.
- Encoding: Label encoding untuk Age dan Education, Binary untuk Gender, dan One-Hot untuk Country dan Ethnicity.
- Target Transformation: Konversi 18 jenis obat menjadi binary class (User vs Non-User).
- Scaling: Standarisasi fitur menggunakan StandardScaler.

3.2 Deep Neural Network Architecture

A. Network Design Philosophy

Prinsip Desain

- Moderate depth (4-5 hidden layers) cukup untuk capture complexity tanpa overfitting
- Pyramidal structure: neurons decreasing: 128 → 64 → 32 → 16
- Strong regularization: Dropout + L2 + BatchNorm
- Binary classification output: sigmoid activation

B. Hyperparameter Search Space

Parameter	Search Space	Description
Architecture		
n_hidden_layers	[3, 4, 5]	Number of hidden layers
layer_1_units	[64, 128, 256]	First layer neurons
layer_2_units	[32, 64, 128]	Second layer neurons
layer_3_units	16, 32, 64]	Third layer neurons
layer_4_units	[8, 16, 32]	Fourth layer neurons

Regularization		
dropout_rate_1	[0.2, 0.3, 0.4]	Dropout after layer 1-2
dropout_rate_2	[0.1, 0.2, 0.3]	Dropout after layer 3-4
l2_regularization	[0.0001, 0.001, 0.01]	L2 penalty
Optimization		
learning_rate	[0.0001, 0.001, 0.01]	Adam learning rate
batch_size	[16, 32, 64]	Training batch size
optimizer	['adam', 'rmsprop']	Optimization algorithm

3.3 Evaluasi Model

- Model dievaluasi menggunakan metrik komprehensif: Utama: Accuracy, ROC-AUC, F1-Score. Tambahan: Sensitivity, Specificity, Precision. Analisis: Kurva Loss (Train vs Val) untuk deteksi overfitting dan SHAP values untuk interpretabilitas fitur.

BAB 4: RENCANA KERJA

4.1 Timeline Pelaksanaan

Week	Aktivitas
1	Setup environment, preprocessing data, dan pembangunan model DNN baseline
2	Hyperparameter tuning menggunakan Keras Tuner dan training model optimal
3	Evaluasi performa model, analisis fitur dengan SHAP, dan perbandingan head-to-head dengan Random Forest
4	Penyusunan laporan akhir, visualisasi hasil, dan dokumentasi GitHub

4.2 Deliverables

A. GitHub Repository Structure

- drug-consumption-dnn-prediction/
 - |— data/
 - |— raw/
 - |— processed/
 - |— notebooks/
 - |— 01_DNN_Training.ipynb
 - |— 02_Evaluation_Comparison.ipynb
 - |— models/
 - |— tuned_rf_model.pkl
 - |— dnn_baseline.h5
 - |— dnn_tuned.h5
 - |— scaler.pkl
 - |— results/
 - |— figures/
 - |— metrics/
 - |— models/keras_tuner/

4.3 Output Dokumen

1. **Laporan Akhir (PDF)**

Berisi pendahuluan, metodologi, hasil analisis, dan kesimpulan.

2. **Source Code**

Repository GitHub lengkap dengan instruksi penggunaan.

BAB 5: KESIMPULAN DAN HARAPAN

5.1 Kesimpulan

Proposal ini menargetkan pengembangan model Deep Neural Network sebagai studi komparasi lanjut terhadap Random Forest. Dengan struktur metodologi yang ketat, penelitian ini bertujuan menjawab apakah kompleksitas DNN sebanding dengan peningkatan performa yang dihasilkan pada data berbasis kepribadian.

5.2 Harapan

- Penelitian ini diharapkan dapat memberikan wawasan empiris mengenai efektivitas Deep Learning pada tabular data berskala menengah dan berkontribusi pada pengembangan sistem pendukung keputusan klinis untuk rehabilitasi narkoba.
-

REFERENSI

Primary:

1. Fehrman, E., et al. (2017). "The Five Factor Model of personality and evaluation of drug consumption risk." arXiv:1506.06297v2.
2. Breiman, L. (2001). "Random forests." Machine Learning, 45(1), 5-32.
3. Lundberg, S. M., & Lee, S. I. (2017). "A unified approach to interpreting model predictions." NeurIPS, 30, 4765-4774.
4. Goodfellow, I., Bengio, Y., & Courville, A. (2016). "Deep Learning." MIT Press.
5. Kingma, D. P., & Ba, J. (2014). "Adam: A method for stochastic optimization." ICLR.
6. Srivastava, N., et al. (2014). "Dropout: A simple way to prevent neural networks from overfitting." JMLR, 15(1), 1929-1958.

7. Ioffe, S., & Szegedy, C. (2015). "Batch normalization: Accelerating deep network training." ICML.
8. Bergstra, J., & Bengio, Y. (2012). "Random search for hyper-parameter optimization." JMLR, 13, 281-305.
9. Schwartz-Ziv, R., & Armon, A. (2022). "Tabular data: Deep learning is not all you need." Information Fusion, 81, 84-90.
10. Grinsztajn, L., et al. (2022). "Why do tree-based models still outperform deep learning on tabular data?" NeurIPS.
11. Borisov, V., et al. (2022). "Deep neural networks and tabular data: A survey." IEEE TNNLS.
12. Rajkomar, A., et al. (2019). "Machine learning in medicine." NEJM, 380(14), 1347-1358.
13. Char, D. S., et al. (2018). "Implementing machine learning in health care." NEJM, 378(11), 981-983.
14. Molnar, C. (2020). "Interpretable machine learning." Lulu.com.
15. Ribeiro, M. T., et al. (2016). "Why should I trust you?: Explaining the predictions of any classifier." KDD, 1135-1144.