

Analisis Komparatif Deep Neural Network dan Random Forest untuk Prediksi Risiko Konsumsi Narkoba Berbasis Personality Traits

Muhammad Ichsan Junaedi¹, Amanda Wijayanti²

^{1,2} Sistem Informasi, Sekolah Tinggi Manajemen Informatika Komputer (STMIK) Tazkia

E-mail : ¹ 2415720100024.ichsan@student.stmik.tazkia.ac.id

² 241572010006.amanda@student.stmik.tazkia.ac.id

Abstrak

Penyalahgunaan narkoba merupakan krisis kesehatan global yang memerlukan metode deteksi dini yang akurat dan non-invasif. Penelitian ini bertujuan untuk mengevaluasi dan membandingkan kinerja pendekatan Deep Learning menggunakan Deep Neural Network (DNN) dengan Machine Learning konvensional (Random Forest) dalam memprediksi risiko konsumsi obat berdasarkan fitur kepribadian (Big Five Personality Traits). Permasalahan utama yang diangkat adalah kecenderungan overfitting pada model berbasis pohon keputusan saat dihadapkan pada dataset dengan dimensi fitur psikologis yang kompleks. Menggunakan dataset Drug Consumption dari UCI Machine Learning Repository (n=1,885), penelitian ini menerapkan metodologi ketat yang meliputi normalisasi fitur, hyperparameter tuning menggunakan Keras Tuner, dan strategi regularisasi berlapis (Dropout, Batch Normalization). Hasil eksperimen menunjukkan bahwa meskipun Random Forest (RF) mencapai nilai ROC-AUC yang sedikit lebih tinggi (0.9094) dibandingkan DNN (0.9088), model RF mengalami masalah generalisasi yang serius dengan gap akurasi training-testing sebesar 16.45%. Sebaliknya, model DNN yang diusulkan menunjukkan stabilitas luar biasa dengan gap generalisasi hanya -0.20% dan Specificity yang lebih unggul (85.11%). Analisis SHAP (SHapley Additive exPlanations) mengonfirmasi bahwa fitur Sensation Seeking dan Openness adalah prediktor deterministik utama. Kesimpulan penelitian ini menegaskan bahwa untuk aplikasi klinis yang menuntut reliabilitas pada data baru, arsitektur DNN dengan regularisasi yang tepat menawarkan solusi yang jauh lebih robust dibandingkan metode ensemble tradisional.

Kata Kunci: Deep Neural Network, Random Forest, Drug Consumption, Personality Traits, Generalization, SHAP Analysis.

Comparative Analysis of Deep Neural Networks and Random Forest for Predicting the Risk of Drug Use Based on Personality Traits

Abstract

Drug abuse is a global health crisis that requires accurate and non-invasive early detection methods. This study aims to evaluate and compare the performance of a Deep Learning approach using Deep Neural Networks (DNN) against conventional Machine Learning (Random Forest) in predicting drug consumption risk based on the Big Five Personality Traits. The primary problem addressed is the tendency of decision-tree-based models to overfit when dealing with datasets containing complex psychological features. Using the Drug Consumption dataset from the UCI Machine Learning Repository (n=1,885), this research implements a rigorous methodology including feature normalization, hyperparameter tuning via Keras Tuner, and layered regularization strategies (Dropout, Batch Normalization). Experimental results demonstrate that while Random Forest (RF) achieved a slightly higher ROC-AUC (0.9094) compared to DNN (0.9088), the RF model suffered from serious generalization issues, with a training-testing accuracy gap of 16.45%. In contrast, the proposed DNN model exhibited remarkable stability with a generalization gap of only -0.20% and superior Specificity (85.11%). SHAP (SHapley Additive exPlanations) analysis confirmed that Sensation Seeking and Openness are the primary deterministic predictors. This study concludes that for clinical applications demanding reliability on unseen data, DNN architectures with proper regularization offer a significantly more robust solution than traditional ensemble methods.

Keywords: Deep Neural Network, Random Forest, Drug Consumption, Personality Traits, Generalization, SHAP Analysis.

1. Pendahuluan

Penyalahgunaan zat adiktif dan narkoba merupakan masalah kesehatan masyarakat yang persisten dengan dampak sosio-ekonomi yang masif. Menurut United Nations Office on Drugs and Crime (UNODC), sekitar 275 juta orang di seluruh dunia menggunakan narkoba setidaknya sekali pada tahun 2020. Identifikasi individu yang memiliki risiko tinggi (high-risk individuals) sebelum terjadinya ketergantungan kronis menjadi kunci dalam strategi pencegahan preventif.

Pendekatan psikologis konvensional sering menggunakan kuesioner kepribadian untuk menilai kecenderungan perilaku berisiko. Teori Five Factor Model (FFM) yang mengukur Neuroticism, Extraversion, Openness, Agreeableness, dan Conscientiousness telah terbukti berkorelasi dengan penggunaan zat. Namun, analisis manual terhadap profil kepribadian seringkali subjektif dan lambat. Oleh karena itu, integrasi Artificial Intelligence (AI), khususnya Machine Learning (ML), menjadi solusi untuk mengotomatisasi pola deteksi risiko ini.

Pada penelitian pendahuluan (Studi UTS), kami telah mengembangkan model prediksi menggunakan algoritma Random Forest. Meskipun model tersebut mencapai akurasi yang tinggi, evaluasi mendalam menunjukkan indikasi overfitting yang signifikan, di mana model sangat akurat pada data latih namun performanya menurun pada data uji. Hal ini mengindikasikan bahwa model tradisional berbasis decision tree memiliki keterbatasan dalam menangkap varians data tanpa menghafal noise, khususnya pada dataset dengan jumlah sampel terbatas (tabular data).

Penelitian ini (Studi UAS) hadir untuk mengisi celah tersebut dengan mengimplementasikan arsitektur Deep Neural Network (DNN). Berbeda dengan shallow learning, DNN memiliki kemampuan representation learning yang memungkinkan ekstraksi fitur secara hirarkis dan non-linear. Tujuan utama penelitian ini adalah: (1) Mengembangkan model DNN yang dioptimasi untuk klasifikasi risiko konsumsi narkoba; (2) Membandingkan performa generalisasi antara DNN dan Random Forest; dan (3) Menganalisis fitur psikologis dominan menggunakan SHAP Analysis untuk memastikan interpretabilitas model. Penelitian ini diharapkan dapat memberikan kontribusi empiris mengenai efektivitas Deep Learning pada data tabular psikologis, serta menyediakan model deteksi dini yang tidak hanya akurat tetapi juga stabil (robust) untuk implementasi klinis.

2. Karya Terkait

2.1 Profiling Kepribadian dan Risiko Penyalahgunaan Zat

Hubungan antara kepribadian dan penggunaan narkoba telah didokumentasikan dengan baik dalam literatur psikologi. Fehrman et al. [1] dalam penelitian seminalnya menggunakan dataset *Drug Consumption* untuk memetakan hubungan antara *Big Five Personality Traits* dan konsumsi berbagai jenis obat. Mereka menemukan bahwa sifat *Sensation Seeking* (pencarian sensasi) dan *High Openness* (keterbukaan tinggi terhadap pengalaman) adalah prediktor terkuat untuk penggunaan obat ilegal. Namun, penelitian Fehrman et al. masih menggunakan pendekatan klasifikasi per-jenis obat (multi-label) yang terfragmentasi, sehingga sulit untuk memberikan skor risiko tunggal yang holistik bagi seorang individu. Penelitian ini menyederhanakan target menjadi klasifikasi biner (*User vs Non-User*) untuk memfasilitasi skrining awal yang lebih praktis.

2.2 Machine Learning pada Data Medis Tabular

Data medis dan psikologis umumnya berbentuk tabular (baris dan kolom). Dalam domain ini, algoritma berbasis Ensemble Tree seperti Random Forest (RF) dan Gradient Boosting (XGBoost) sering dianggap sebagai standar emas (gold standard) [2]. Breiman [3] menjelaskan bahwa RF efektif karena kemampuannya menangani outlier dan non-linear features melalui mekanisme bagging. Namun, kelemahan utama dari model berbasis pohon adalah kecenderungan untuk tumbuh terlalu kompleks (high variance), yang menyebabkan overfitting pada dataset dengan jumlah sampel menengah (< 5.000 sampel), seperti yang ditemukan pada dataset studi ini.

2.3 Deep Learning untuk Data Tabular: Peluang dan Tantangan

Meskipun *Deep Learning* (DL) mendominasi bidang *Computer Vision* dan NLP, penerapannya pada data tabular masih menjadi perdebatan. Grinsztajn et al. [4] dalam papernya "*Why do tree-based models still outperform deep learning on tabular data?*" berargumen bahwa model DL sering kesulitan menangani fitur yang tidak memiliki korelasi spasial, serta sensitif terhadap *unscaled data*.

Namun, studi terbaru menunjukkan bahwa dengan teknik regularisasi modern (seperti *Dropout* dan *Batch Normalization*) serta optimasi *hyperparameter* yang tepat, model *Deep Neural Network* (DNN) atau *Multilayer Perceptron* (MLP) dapat menyaingi atau bahkan melampaui stabilitas model tradisional [5]. DNN memiliki keunggulan dalam fleksibilitas fungsi objektif dan kemampuan belajar representasi (embedding). Penelitian ini menguji hipotesis tersebut dengan menerapkan arsitektur DNN piramidal yang dilengkapi regularisasi ketat untuk mengatasi masalah generalisasi yang ditemukan pada model Random Forest sebelumnya.

3. Metodologi Penelitian

3.1 Dataset dan Preprocessing

Penelitian ini menggunakan *Drug Consumption (Quantified) Dataset* dari UCI Machine Learning Repository. Dataset terdiri dari 1.885 responden dengan 32 atribut awal.

1. **Feature Selection:** Fitur input terdiri dari 12 variabel utama: Demografi (Usia, Gender, Pendidikan, Negara, Etnis) dan Psikometrik (Nscore, Escore, Oscore, Ascore, Cscore, Impulsiveness, Sensation Seeking).
2. **Target Engineering:** Variabel target dikonsolidasi dari 18 jenis obat menjadi klasifikasi biner. Kelas "User" (1) didefinisikan sebagai individu yang mengonsumsi obat ilegal minimal sekali dalam satu tahun terakhir, sedangkan "Non-User" (0) adalah sebaliknya.
3. **Data Splitting:** Data dibagi menjadi *Training Set* (80%, n=1.508) dan *Testing Set* (20%, n=377) menggunakan teknik *Stratified Sampling* untuk mempertahankan rasio ketidakseimbangan kelas (Imbalance Ratio 0.60:1).

Transformasi Skala (Scaling):

Salah satu perbedaan fundamental dalam perlakuan data untuk DNN dibandingkan RF adalah kebutuhan normalisasi. Kami menerapkan Standard Scaler $Z = \frac{x-\mu}{\sigma}$ pada seluruh fitur input. Hal ini krusial karena DNN menggunakan optimasi berbasis gradien (Gradient Descent), di mana fitur dengan skala besar dapat mendominasi pembaruan bobot dan memperlambat konvergensi.

3.2 Arsitektur Deep Neural Network (DNN)

Kami merancang arsitektur Multilayer Perceptron (MLP) dengan struktur piramidal menurun untuk memaksa jaringan melakukan kompresi fitur (feature compression).

- **Input Layer:** Sesuai dimensi fitur (12 neuron).
- **Hidden Layers:** Tiga lapisan tersembunyi dengan konfigurasi *neuron* [256 → 32 → 64] (berdasarkan hasil tuning terbaik).
- **Activation Function:** Menggunakan Rectified Linear Unit (ReLU) pada hidden layer untuk mengatasi vanishing gradient problem:

$$f(x) = \max(0, x)$$

- **Output Layer:** Satu neuron dengan fungsi aktivasi Sigmoid untuk menghasilkan probabilitas biner:

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

3.3 Strategi Regularisasi dan Optimasi

Masalah utama pada penelitian sebelumnya adalah *overfitting*. Untuk mengatasinya, strategi berikut diterapkan pada model DNN:

1. **Dropout:** Menerapkan tingkat *dropout* sebesar 0.4 pada layer awal. Teknik ini secara acak "mematikan" neuron selama proses training, memaksa jaringan untuk mempelajari fitur yang lebih robust dan tidak bergantung pada neuron tertentu saja.
2. **Batch Normalization:** Menstabilkan distribusi input pada setiap layer internal.
3. **L2 Regularization:** Menambahkan penalti pada fungsi *loss* untuk bobot yang terlalu besar.
4. **Early Stopping:** Menghentikan pelatihan secara otomatis jika *validation loss* tidak membaik selama 20 *epoch* berturut-turut.

Layer (type)	Output Shape	Param #
dense_1 (Dense)	(None, 128)	1,664
dropout_1 (Dropout)	(None, 128)	0
dense_2 (Dense)	(None, 64)	8,256
dropout_2 (Dropout)	(None, 64)	0
dense_3 (Dense)	(None, 32)	2,080
dropout_3 (Dropout)	(None, 32)	0
dense_4 (Dense)	(None, 16)	528
dropout_4 (Dropout)	(None, 16)	0
output (Dense)	(None, 1)	17

Total params: 12,545 (49.00 KB)

Trainable params: 12,545 (49.00 KB)

Non-trainable params: 0 (0.00 B)

Gambar 1. Arsitektur Model DNN

3.4 Konfigurasi Hyperparameter Tuning

Optimasi *hyperparameter* dilakukan menggunakan kerangka kerja *Keras Tuner* dengan metode *Random Search*. Ruang pencarian meliputi jumlah layer (3-5), jumlah neuron (16-256), *learning rate* (1e-4 hingga 1e-2), dan tipe *optimizer* (Adam vs RMSprop). Fungsi tujuan optimasi adalah memaksimalkan nilai ROC-AUC pada data validasi.

4. Hasil dan Pembahasan

4.1 Dinamika Pelatihan Model (Training Dynamics)

Proses pelatihan model DNN dilakukan selama maksimal 150 epoch dengan mekanisme *Early Stopping*. Berdasarkan kurva pembelajaran (*learning curve*), model berhenti konvergen pada epoch ke-31, yang mengindikasikan efisiensi waktu komputasi.



Gambar 2. Kurva Loss dan AUC pada Training vs Validation

Grafik pada Gambar 2 menunjukkan fenomena yang sangat positif: kurva *Validation Loss* (garis oranye) berhimpitan sangat rapat dengan *Training Loss* (garis biru). Tidak terjadi divergensi (pemisahan) yang melebar seiring bertambahnya epoch. Ini adalah indikator kuat bahwa model DNN yang dibangun memiliki varians rendah dan tidak mengalami *overfitting*, berbeda dengan karakteristik umum model *Random Forest* yang seringkali memiliki akurasi training 100% namun jatuh pada validasi.

4.2 Evaluasi Komparatif: DNN vs Random Forest

Tabel 1 menyajikan perbandingan kinerja komprehensif antara model *Random Forest* (Baseline UTS yang di-tune) dan *Deep Neural Network* (Model Final UAS) pada data uji (*Test Set*).

Tabel 1. Perbandingan Metrik Performa pada Data Uji

Metrik Evaluasi	Deep Neural Network (DNN)	Random Forest (RF)	Analisis Selisih
Accuracy	83.82%	83.55%	DNN +0.27%
ROC-AUC	0.9088	0.9094	RF +0.06%
F1-Score	0.8653	0.8686	RF +0.33%
Precision	90.32%	86.86%	DNN +3.46%
Sensitivity (Recall)	83.05%	86.86%	RF +3.81%
Specificity	85.11%	78.01%	DNN +7.10%

Secara statistik, kedua model menunjukkan performa yang sangat kompetitif dan seimbang. *Random Forest* unggul tipis dalam kemampuan membedakan rangking probabilitas (ROC-AUC) dan sensitivitas (Recall). Namun, DNN menunjukkan keunggulan signifikan dalam **Precision** dan **Specificity**.

Artinya, ketika model DNN memprediksi seseorang sebagai "User", probabilitas kebenarannya lebih tinggi (90.32%) dibandingkan RF (86.86%). Dalam konteks intervensi klinis, Specificity yang tinggi (85.11%) pada DNN sangat berharga untuk mengurangi *False Positive*, yaitu menghindari tuduhan salah terhadap individu yang sebenarnya tidak berisiko (Non-User).

4.3 Analisis Generalisasi dan Overfitting


Temuan paling kritikal dalam penelitian ini bukanlah pada akurasi absolut, melainkan pada **stabilitas generalisasi**. Tabel 2 memperlihatkan *gap* atau selisih performa antara fase *training* dan *testing*.

Tabel 2. Analisis Stabilitas Model (Overfitting Gap)

Model	Training Accuracy	Testing Accuracy	Gap (Overfitting)	Status
Random Forest	100.00%	83.55%	16.45%	<i>High Overfitting</i>
DNN (Tuned)	83.62%	83.82%	-0.20%	<i>Excellent Generalization</i>

Data pada Tabel 2 menjawab permasalahan utama penelitian. Model *Random Forest* mencapai akurasi sempurna (100%) pada data latih, yang merupakan tanda klasik bahwa model "menghafal" data (*memorization*). Hal ini menyebabkan penurunan performa sebesar 16.45% saat diuji pada data baru.


Sebaliknya, model DNN yang dilengkapi dengan *Dropout* dan *L2 Regularization* mempertahankan konsistensi yang luar biasa. Akurasi pada data latih (83.62%) hampir identik dengan data uji (83.82%). Gap negatif (-0.20%) bahkan menunjukkan bahwa model bekerja sedikit lebih baik pada data uji, menandakan bahwa regularisasi berhasil memaksa model mempelajari pola general (*latent features*) alih-alih menghafal *noise*.



Gambar 3. Visualisasi Perbandingan Metrik (Bar Chart)

4.4 Interpretasi Fitur dengan SHAP Analysis

Salah satu kritik terhadap *Deep Learning* adalah sifatnya yang *black-box*. Untuk memastikan akuntabilitas medis, kami menggunakan *SHAP* (*SHapley Additive exPlanations*) guna membedah fitur mana yang paling berpengaruh pada keputusan model DNN.



Gambar 4. Perbandingan Feature Importance: DNN (SHAP) vs Random Forest

Berdasarkan Gambar 4, terdapat konsistensi temuan fitur penting antara kedua model:

1. **Country (Negara):** Menjadi faktor dominan, mengindikasikan adanya pengaruh geopolitik dan ketersediaan akses terhadap narkoba di wilayah tertentu (khususnya UK dan USA dalam dataset ini).
2. **Oscore (Openness to Experience):** Fitur kepribadian teratas. Individu dengan skor keterbukaan tinggi cenderung lebih berani bereksperimen dengan zat baru.
3. **Age (Usia):** Faktor demografis krusial, di mana usia muda berkorelasi kuat dengan risiko penggunaan.
4. **Sensation Seeking (SS):** Fitur perilaku yang secara konsisten muncul di papan atas, merepresentasikan dorongan biologis untuk mencari rangsangan sensori.

Konsistensi ini memvalidasi bahwa model DNN mempelajari sinyal kausalitas yang benar dari data, bukan korelasi semu (spurious correlation).

5. Diskusi

Hasil penelitian ini memberikan wawasan empiris mengenai perdebatan "Machine Learning Klasik vs Deep Learning" pada data tabular. Jika tujuannya semata-mata adalah nilai AUC tertinggi, *Random Forest* masih menjadi pilihan yang valid karena efisiensi komputasinya. Namun, dalam aplikasi dunia nyata (*real-world deployment*), stabilitas model adalah segalanya.

Model *Random Forest* yang *overfit* berisiko gagal total jika distribusi data di masa depan sedikit bergeser (*data drift*). Model DNN yang kami kembangkan, meskipun membutuhkan daya komputasi lebih tinggi untuk pelatihan, menawarkan jaminan keamanan yang lebih baik karena terbukti resisten terhadap *overfitting*.

Selain itu, tingginya *Precision* pada DNN menjadikannya alat yang lebih etis untuk skrining awal, meminimalkan stigma yang mungkin timbul akibat kesalahan pelabelan individu sehat sebagai pengguna narkoba.

6. Kesimpulan dan Saran

Penelitian ini berhasil mengembangkan dan mengevaluasi model *Deep Neural Network* untuk prediksi risiko konsumsi narkoba. Berdasarkan analisis komparatif dengan *Random Forest*, dapat disimpulkan bahwa:

1. **Stabilitas vs Akurasi Murni:** DNN menawarkan kemampuan generalisasi yang jauh lebih superior (Gap < 1%) dibandingkan *Random Forest* (Gap > 16%), menjadikannya model yang lebih andal untuk data baru.
2. **Kinerja Kompetitif:** Meskipun merupakan data tabular, DNN yang dioptimasi mampu menyamai performa ROC-AUC algoritma *ensemble* (0.9088 vs 0.9094).
3. **Prediktor Utama:** Analisis SHAP mengonfirmasi bahwa *Sensation Seeking*, *Openness*, dan faktor demografis adalah indikator risiko utama yang harus menjadi fokus dalam intervensi psikologis.

Saran Pengembangan:

Penelitian selanjutnya disarankan untuk:

1. Mengeksplorasi arsitektur TabNet yang menggabungkan keunggulan attention mechanism pada data tabular.
2. Menerapkan teknik SMOTE atau Class Weighting yang lebih agresif pada DNN untuk meningkatkan Sensitivity.
3. Melakukan validasi eksternal pada dataset dari negara dengan budaya berbeda untuk menguji bias fitur Country.

Ucapan Terima Kasih

Penulis mengucapkan terima kasih kepada Bapak Hendri Kharisma S.Kom, M.T selaku dosen pengampu yang telah memberikan bimbingan, serta kepada penyedia dataset UCI Machine Learning Repository atas akses data terbuka yang memungkinkan penelitian ini terlaksana.

Daftar Pustaka

- [1] E. Fehrman, A. K. Muhammad, E. M. Mirkes, V. Egan, and A. N. Gorban, "The Five Factor Model of Personality and Evaluation of Drug Consumption Risk," *arXiv preprint arXiv:1506.06297*, 2017.
- [2] L. Breiman, "Random Forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [3] L. Grinsztajn, E. Oyallon, and G. Varoquaux, "Why do tree-based models still outperform deep learning on tabular data?," in *NeurIPS 2022 Datasets and Benchmarks Track*, 2022.
- [4] S. M. Lundberg and S. I. Lee, "A Unified Approach to Interpreting Model Predictions," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
- [5] V. Borisov et al., "Deep neural networks and tabular data: A survey," *IEEE Transactions on Neural Networks and Learning Systems*, 2022.
- [6] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, "Dropout: A Simple Way to Prevent Neural Networks from Overfitting," *Journal of Machine Learning Research*, vol. 15, pp. 1929–1958, 2014.
- [7] S. Ioffe and C. Szegedy, "Batch normalization: Accelerating deep network training by reducing internal covariate shift," in *International Conference on Machine Learning (ICML)*, 2015.
- [8] D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization," in *International Conference on Learning Representations (ICLR)*, 2015.
- [9] F. Chollet et al., *Deep Learning with Python*, Manning Publications, 2017.
- [10] T. O'Malley et al., "Keras Tuner," <https://github.com/keras-team/keras-tuner>, 2019.
- [11] M. Shahbaz, S. Ali, A. Guergachi, A. Niazi and A. Umer, "Classification of Alzheimer's Disease using Machine Learning Techniques," *Classification of Alzheimer's Disease using Machine Learning Techniques*, pp. 296-303, 2019.
- [12] G. Cappiello and F. Caruso, "Quantum AI for Alzheimer's disease early screening," *Neurocomputing*, vol. 602, p. 130565, 2025.